신뢰할 수 있는 인공지능 분석 보고서

이지원

RESNET-18 모델을 MNIST, CIFAR-10 데이터셋으로 각각 학습한 RESNET-18 두 모델을 사용하였다. Target의 경우 **class 8**을 target하도록 설정하였다. 성공률 평가는 모델이 올바르게 예측한 sample 그리고 target의 경우 해당 target과 다른 sample들로 필터링하여 총 **100**개의 sample로 맞추어 평가를 진행하였다.

FGSM 공격에서 두 데이터셋에서 epsilon에 따른 공격 성공률이 전혀 다른 양상을 보인다. MNIST 데이터셋의 경우 epsilon이 증가할수록 성공률도 함께 증가하는 경향을 보인다. FGSM은 epsilon의 크기만큼 입력에 perturbation을 주는 방식으로 MNIST 데이터셋의 경우 조금의 변형으로는 공격이 어렵다. 이는 MNIST로 학습한 RESNET-18모델의 decision boundary가 명확하게 나누어져 있으며, 공격의 보폭이 더 커야 모델의 decision boundary를 넘는 샘플이 증가하는 것으로 해석할 수 있다.

반면 CIFAR-10에서는 untargeted에서 작은 epsilon에서도 매우 성공률을 보였으며, targeted는 오히려 epsilon이 증가할수록 성공률이 감소하였다. CIFAR-10은 배경, color 이미지 데이터셋으로 CIFAR-10으로 학습한 RESNET-18 모델의 decision boundary가 MNIST보다 불안정하기 때문에 작은 perturbation만으로도 정답 클래스로부터 벗어나게 만들기 쉽기 때문으로 보인다.

targeted 공격은 특정 class 8로의 유도를 요구하기 때문에 1-step FGSM의 보폭이 너무 커지면 원하는 target으로 정밀하게 이동하지 못하고 다른 class로 이동해버리기 때문에 공격 성공이 낮게 나타나는 것으로 보인다. CIFAR-10에서는 낮은 epsilon만으로도 높은 성공률을 보이며 MNIST보다 더 효율적인 공격을 가능함을 보여준다. 다만 CIFAR-10 Untargeted 결과에서 epsilon 증가에 따라 성공률이 소폭 감소하는 현상은 1-step FGSM의 불안정성, clipping 효과, 평가 샘플의 영향 가능성을 함께 고려할 필요가 있다.

Table 1: FGSM attack success rate by dataset, attack type, and epsilon

Setting	$\epsilon = 0.05$	$\epsilon = 0.1$	$\epsilon = 0.2$	$\epsilon = 0.3$
MNIST Untargeted	0.01	0.14	0.59	0.82
MNIST Targeted	0.01	0.09	0.56	0.92
CIFAR-10 Untargeted	0.96	0.97	0.91	0.87
CIFAR-10 Targeted	0.73	0.50	0.14	0.04

PGD 공격의 parameter는 epsilon_step=0.01, epsilon은 {0.05, 0.1, 0.2, 0.3}, k=40(MNIST), k=10(CIFAR-10)으로 설정하였다. Sample 수는 FGSM 공격과 동일한 방식으로 총 100개의 sample로 맞추어 평가를 진행하였다.

PGD 공격은 MNIST 데이터로 학습한 모델에서 epsilon=0.1까지 소폭 증가하다가 epsilon=0.2부터 완벽한 성공률을 달성한다. 1-step FGSM과 달리, PGD가 반복적인 gradient update와 projection을 통해 입력을 정교하게 decision boundary로 이동시키기 때문으로 해석된다.

반면 CIFAR-10 데이터로 학습한 모델은 epsilon=0.05에서 부터 완벽한 성공률을 달성하며 모든 epsilon에서 완벽한 성공률을 보인다. CIFAR-10 Targeted는 전체 epsilon에서 높은 성공률을 보이므로 perturbation visibility가 가장 좋은 epsilon=0.05로 공격을 하는 것이 공격자의 입장에서 좋은 공격 방법이 될 것이다.

Table 2: PGD attack success rate by dataset, attack type, and epsilon

Setting	$\epsilon = 0.05$	$\epsilon = 0.1$	$\epsilon = 0.2$	$\epsilon = 0.3$
MNIST Untargeted	0.03	0.22	1.00	1.00
MNIST Targeted	0.01	0.15	1.00	1.00
CIFAR-10 Untargeted	1.00	1.00	1.00	1.00
CIFAR-10 Targeted	1.00	1.00	1.00	1.00

CIFAR-10 Untargeted FGSM Figure

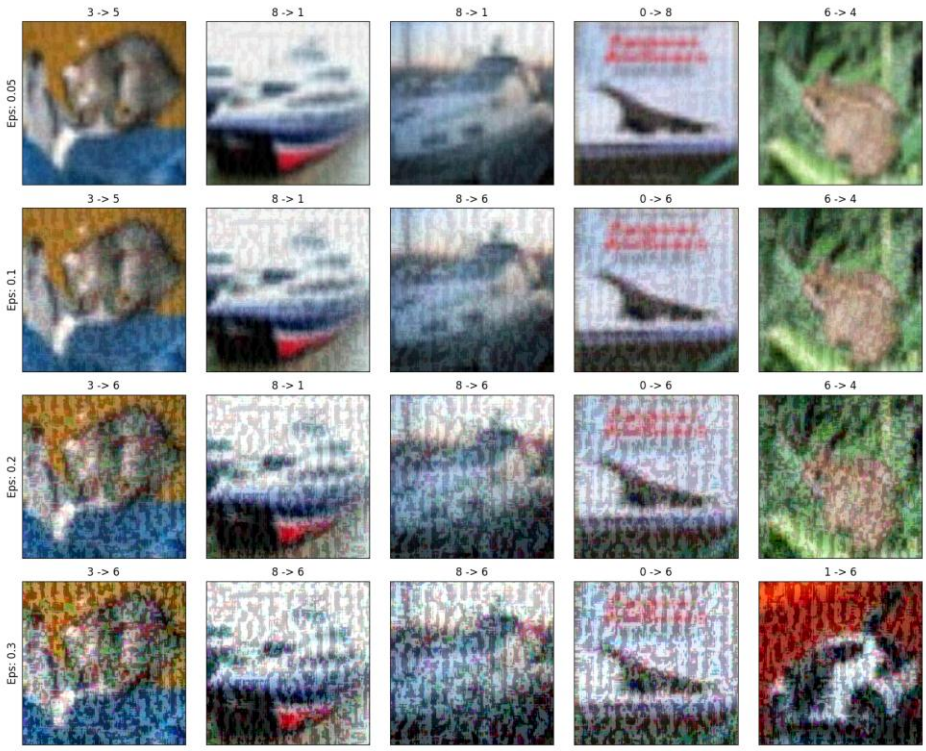

CIFAR-10 Targeted PGD Figure